

QS

April 28, 2026

0.1 Quicksort versione Las Vegas e Monte Carlo - Implementazione e Analisi

L'Algoritmo Quicksort(S) affronta il classico problema dell'**ordinamento di una sequenza** S di n **numeri**. Le sue **prestazioni** dipendono dall'**ordinamento iniziale** di S ; nel **caso peggiore**, nel quale si verificano partizionamenti della sequenza sfavorevoli, l'algoritmo **deterministico** ha una complessita' temporale $O(n^2)$. Di seguito vengono proposte due versioni **randomizzate** dell'algoritmo che, con piu' o meno successo, tentano di allontanarsi dal **caso peggiore** e ottengono un numero atteso di confronti pari a $O(n \log n)$.

Il **determinismo** del primo algoritmo si trova nella *scelta esplicita* di quale elemento considerare come *pivot*, ossia, ad ogni iterazione dell'algoritmo, quale elemento p usiamo come base delle *partizioni* $S_{<}, p, S_{\geq}$. Un esercizio che abbiamo visto a lezione e' stato quello di creare la **sequenza peggiore** per una determinata posizione del *pivot*, infatti proprio per la *scelta esplicita* di quest'ultima e' facile capire come generarla. Ad esempio per la versione **deterministica** di Quicksort(S) che sceglie come *pivot* l'elemento *mediano* e' sufficiente scrivere gli n numeri inserendo nella posizione *mediana* il numero piu' *piccolo* (o piu' *grande*) della sequenza ancora da ordinare.

Ora passiamo al codice, inizio impostando l'ambiente e definendo la sequenza S da analizzare, con $|S| = 10^4$

```
[112]: # Imports
import IPython
import warnings

import random
import math

import matplotlib.pyplot as plt

PATH = "../data/"
N = int(1e4) # 10^4 int
```

```
[118]: # returns a list of n random int between 0 and 100
def sequence_generator(n):
    s = []
    for i in range(n):
        s.append(random.randint(0, 100))
    return s
# helper swap function
```

```
def swap(s, a, b):
    tmp = s[b]
    s[b] = s[a]
    s[a] = tmp

s = sequence_generator(N) # random sequence of int
```

0.1.1 Las Vegas Quicksort:

Procediamo ora a definire LVQuicksort(S), prima versione **randomizzata** derivata dall'omonimo **deterministico** che, al posto di effettuare una *scelta irrevocabile esplicita* del *pivot*, ad ogni chiamata lo campiona con *probabilit  uniforme* su tutta la sequenza ancora da ordinare.

L'algoritmo presentato   considerato di tipo **Las Vegas** in quanto *fornisce sempre l'output corretto anche se, sullo stesso input   eseguito in istanti diversi $t_1, t_2 | t_1 \neq t_2$* . Ad ogni chiamata l'algoritmo si comporter  esattamente come la versione deterministica e perci  nel **caso peggiore** coster  sempre $O(n^2)$. Per stimare il numero atteso di confronti X nel caso migliore invece, considerate delle variabili indicatrici $I(i, j)$ che indicheranno se i, j vengono confrontati, equivale a calcolare il valore atteso $\mathbb{E}[X] = \mathbb{E}[\sum_{i=1}^{n-1} \sum_{j=i+1}^n I(i, j)]$ che, per la *propriet  della linearit  del valore atteso*, se $p_{ij}(1)$   la probabilit  che i e j siano confrontati il **valore atteso del numero di confronti** X diventa $\mathbb{E}[X] = \sum_{i=1}^{n-1} \sum_{j=i+1}^n p_{ij}(1)$. Si hanno soli due casi favorevoli di confrontare i e j , $I(i, j)$ e $I(j, i)$, dunque $p_{ij} = \frac{2}{j-i+1}$. Seguendo le note, per n , numero di elementi della sequenza, **grande** il **valore atteso del numero di confronti**   approssimabile a $\mathbb{E}[X] = O(n \log n)$.

Ricapitolando, LVQuicksort(S), come nel caso **deterministico**, avr  complessit  $T_{\text{best}} = O(n \log n)$ e $T_{\text{worst}} = O(n^2)$. Il vantaggio di quest'algoritmo deriva dalla scelta **randomica** del *pivot* e dell'impossibilit  di creare sequenze pessime prevedibili.

Propongo un'implementazione dell'algoritmo LVQuicksort(s) basato su quello classico (Recuperato da un laboratorio di ASD).

```
[ ]: # Las Vegas Quicksort
count = 0
limit = float('inf')

def r_quick_sort(s, start, end):
    global count, limit
    if start < end:
        pivot = random.randint(start, end) # random index
        swap(s, start, pivot) # the pivot is now at the start of the partition
        pivot = start
        # partition
        i = start+1
        j = end
        while j >= i:
            count += 1 # global variable that stores the number of comparisons
            if count >= limit: return False # MCQuicksort(S, k), if count >= 2u
            if s[j] < s[pivot]:
                swap(s, i, j)
                i += 1
            else:
                j -= 1
        swap(s, pivot, i)
    return True
```

```

        swap(s, i, j)
        i+=1
        j+=1
    swap(s, pivot, i-1)
    pivot = i-1
    # recursive calls
    if pivot > start:
        if not r_quick_sort(s, start, pivot-1): return False
    if pivot < end:
        if not r_quick_sort(s, pivot+1, end): return False
    return True

def lv_quicksort(s):
    global count, limit

    count = 0
    limit = float('inf') # classic LVQuicksort(S) doesnt have a limit
    if len(s) <= 1:
        return count # number of comparisons
    else:
        r_quick_sort(s, 0, len(s) - 1)
        return count

```

L'implementazione presentata ritorna il **numero totale di confronti effettuati** per ordinare la sequenza s grazie ad un banale contatore.

L'algoritmo LVQuicksort(S), come sopra scritto, ha la stessa complessita' della versione **deterministica**, nel caso peggiore avra' quindi un costo di $O(n^2)$, in seguito sara' presentato un metodo, sfruttando la *teoria della probabilita'*, di minimizzare la frequenza del caso T_{worst} .

0.1.2 Monte Carlo Quicksort:

Abbiamo detto che scelte casuali del pivot possono, con bassa probabilita', richiedere $O(n^2)$ confronti.

Definiamo quindi MCQuicksort(S, k), algoritmo di tipo **Monte Carlo** che non fa altro che eseguire k volte LVQuicksort(S) (con qualche accortezza) per ottenere una complessita', ossia il **numero di confronti**, nel caso peggiore $T_{\text{worst}} = O(n \log n)$. Essendo pero' un algoritmo di tipo **Monte Carlo**, MCQuicksort(S, k) potrebbe fallire e non ordinare la sequenza S (il perche' sara' chiarito in seguito). Cio' puo' avvenire con una probabilita' che, scelto un k opportuno, puo' esser resa *infinitesimamente* piccola.

Ricordando la *disuguaglianza di Markow*:

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}[X]}{a}, \quad \mathbb{E}[X] \text{ Valore atteso di una variabile casuale } X \geq 0, \forall a$$

$$\text{Per } a = 2\mathbb{E}[X] \text{ la disuguaglianza diventa } \mathbb{P}(X \geq 2\mathbb{E}[X]) \leq \frac{\mathbb{E}[X]}{2\mathbb{E}[X]} = \mathbb{P}(X \geq 2\mathbb{E}[X]) \leq \frac{1}{2}.$$

Questa disuguaglianza e' alla base del secondo algoritmo infatti, se X e' la variabile casuale che all' i -esima iterazione di LVQuicksort(S) ordina la sequenza S in x_i confronti e $k > 0 \in$ avremo:

```
[115]: def mc_quicksort(s, k):
    global count, limit

    n = len(s)
    u = n * math.log2(n) # estimated expected value of the number of
    ↪ comparisons necessary to order s, E[X] = nlog(n)
    limit = 2*u

    for i in range(k):
        s_copy = list(s)
        count = 0

        if not r_quick_sort(s_copy, 0, n-1): # if x > 2(nlog(n)) -> discard
        ↪ iteration
            continue
        else:
            return s_copy
```

Come annunciato poco fa, essendo un algoritmo di tipologia **Monte Carlo**, MCQuicksort(S, k) potrebbe fallire e non ordinare la sequenza S , infatti nel caso in cui tutte le k iterazioni ordinassero la sequenza S in un numero di confronti superiore a $2\hat{\mu}$, allora la procedura di ordinamento fallisce. Nel caso peggiore MCQuicksort(S, k) ordina la sequenza nell'**ultima iterazione** con un costo che non è superiore a $2k\hat{\mu} \approx 2kE[X]$ e quindi sempre in $O(n \log n)$ confronti. Tutto sta nello scegliere un k opportuno per rendere trascurabile la probabilità di *insuccesso* dell'algoritmo.

Procediamo adesso a **testare** l'algoritmo **Las Vegas** e creiamo un *istogramma* delle frequenze dei numeri di confronti effettuati in i iterazioni di LVQuicksort(S).


```
[116]: k = int(1e3) # 10^3 run
def iter_lvqs(s, k):
    x = []
    for i in range(k):
        s_copy = list(s)
        x.append(lv_quicksort(s_copy))
    return x
x = iter_lvqs(s, k)

u = sum(x) / len(x)
print(f"\nEmpirical Average of comparisons: {u}")
limit = 2*u

plt.hist(x, bins='auto')
plt.axvline(u, color='r', linestyle='dashed', label=rf'Average  $\hat{\mu}$ 
    ↪ ({u})')
plt.axvline(limit, color='g', linestyle='dashed', label=rf'Limit
    ↪  $2\hat{\mu}$  ({limit})')
plt.xlabel('Number of comparisons')
plt.ylabel('Frequency')
```

```
plt.legend()
plt.show()
```

Empirical Average of comparisons: 578828.177



dall'*istogramma* calcolato possiamo dedurre come in realta', **empiricamente**, nessuna delle k iterazioni raggiunge il limite $2\hat{\mu} = 2\mathbb{E}[X]$, per questo motivo possiamo definire la *disuguaglianza di Markow* pessimista.

Consideriamo ora $k = 10^5$ iterazioni, supponiamo che tali siano sufficienti ad approssimare la pmf vera, proviamo quindi a sostituire $\mathbb{E}[X]$ con $\hat{\mu}$, ponendo $\epsilon = 10^{-5}$, e verifichiamo se $\mathbb{P}(X \geq 2\hat{\mu}) \leq \epsilon$ sia molto piu' precisa di $\mathbb{P}(X \geq 2\mathbb{E}[X]) \leq \frac{1}{2}$ o meno.

```
[117]: k = int(1e5) # 10^5 run
def iter_lvqs(s, k):
    x = []
    for i in range(k):
        s_copy = list(s)
        x.append(lv_quicksort(s_copy))
    return x
x = iter_lvqs(s, k)
```

```

u = sum(x) / len(x) #  $E[X] = u$ 
print(f"\nEmpirical Average of comparisons: {u}")
limit = 2*u

epsilon = 1e-5
limit_cases = 0


for i in x:
    if i >= limit:
        limit_cases += 1
p = limit_cases / len(x) #  $P(X \geq 2u)$ 

plt.hist(x)
plt.axvline(u, color='r', linestyle='dashed', label=rf'Average  $\hat{\mu}_u$  ↪({u})')
plt.axvline(limit, color='g', linestyle='dashed', label=rf'Limit ↪ $2\hat{\mu}_u$  ({limit})')

text = rf'$P(X \geq 2\hat{\mu}_u) = {p} \leq \epsilon = {epsilon}$'
plt.text(0.5, 0.05, text,
        horizontalalignment='center',
        verticalalignment='bottom',
        transform=plt.gca().transAxes)
plt.xlabel('Number of comparisons')
plt.ylabel('Frequency')
plt.legend()
plt.show()

```

Empirical Average of comparisons: 578836.32247



Poiche' $\mathbb{P}(X \geq 2\hat{\mu}) = 0 \leq \epsilon = 10^{-5}$ possiamo affermare che la nuova disuguaglianza e' di molto piu' precisa (di quattro ordini di grandezza) della precedente.

Ora calcoliamo, utilizzando la nuova disuguaglianza appena scoperta, la probabilita' con cui MCQuicksort(S, k) ordina la sequenza S .

- Secondo la disuguaglianza di Markov: $\mathbb{P}(X \geq 2\mathbb{E}[X]) \leq \frac{1}{2}$, si ha una probabilita' che tutti i k tentativi falliscano pari a $\frac{1}{2^k}$, in questo caso, considerato $k = 3$, $\mathbb{P}_{\text{failure}} = \frac{1}{8}$.
- Utilizzando invece $\mathbb{P}(X \geq 2\hat{\mu}) \leq \epsilon$, $\mathbb{P}_{\text{failure}} \leq 10^{-5}$ quindi, su $k = 3$ tentativi, avremo $\mathbb{P}_{\text{failure}} \leq \epsilon^3 = 10^{-15}$.

Possiamo dunque notare come la probabilita' di fallimento sia drasticamente scesa, garantendo un successo molto piu' probabile.

Baldini Filippo - 6393212